

LAPORAN AKHIR

PROYEK PENGANTI UAS

Mata Kuliah Kecerdasan Buatan

Semester Genap 2025/2026

Deep Learning-Based Plant Disease Identification Using Convolutional Neural Networks

Subjudul: Convolutional Neural Network (CNN)

Disusun oleh:

Nabiel Harits Utomo	2306267044
Muhammad Pavel	2306242363
R. Aisha Syauqi Ramadhani	2306250554
Zhafira Zahra Alfarisy	2306250636

Dosen Pengampu:

Muhammad Firdaus Syawaludin Lubis,
S.T., M.T., Ph.D.

DEPARTEMEN TEKNIK KOMPUTER

FAKULTAS TEKNIK

UNIVERSITAS INDONESIA

MEI 2026

LEMBAR PERNYATAAN ORISINALITAS

Kami yang bertandatangan di bawah ini menyatakan bahwa laporan ini, beserta seluruh isinya (termasuk Sub-bab IV.x masing-masing anggota dan berkas metadata.json yang merupakan bagian tidak terpisahkan), adalah hasil karya kelompok kami sendiri. Setiap kutipan, kode, atau gambar yang berasal dari sumber lain telah disitasi dengan benar. Penggunaan AI *assistant* telah dideklarasikan secara jujur pada Sub-bab IV.x.2.

Nabiel Harits Utomo
2306267044



Muhammad Pavel
2306242363



R. Aisha Syauqi Ramadhani
2306250554



Zhafira Zahra Alfarisy
2306250636



DAFTAR ISI

LAPORAN AKHIR.....	1
LEMBAR PERNYATAAN ORISINALITAS.....	1
DAFTAR ISI.....	2
DAFTAR TABEL.....	5
ABSTRAK.....	6
BAB 1.....	7
1.1 Topik yang Dipilih.....	7
1.2 Rumusan Masalah.....	7
1.3 Tujuan Proyek.....	7
1.4 Ruang Lingkup & Batasan.....	8
BAB 2 PENDEKATAN AI.....	9
2.1 Tinjauan Pustaka (Related Work).....	9
2.2 Landasan Teori Model yang Dipilih.....	9
2.2.1 Custom CNN (Baseline Model).....	9
2.2.2 MobileNetV2 (Main Model).....	11
2.3 Justifikasi Ilmiah Pemilihan Pendekatan AI.....	12
2.4 Block Diagram Sistem End-to-End.....	12
2.5 Flowchart Program.....	12
BAB 3.....	13
3.1 Dataset & Pra-pemrosesan.....	13
3.2 Konfigurasi Eksperimen.....	14
3.3 Metrik Evaluasi.....	14
3.4 Hasil Kuantitatif.....	16
3.5 Analisis Hyperparameter Tuning.....	16
3.6 Hasil Kualitatif & Error Analysis.....	16
3.7 Pembahasan.....	16
BAB 4.....	17
4.1 Nabiel Harits Utomo – NPM. 2306267044.....	17
4.1.1 Komponen yang Dikerjakan.....	17
4.1.2 Pernyataan Penggunaan AI Assistant.....	17
4.2 Muhammad Pavel – NPM. 2306242363.....	17
4.2.1 Komponen yang Dikerjakan.....	17
4.2.2 Pernyataan Penggunaan AI Assistant.....	18
4.3 R. Aisha Syauqi Ramadhani – NPM. 2306250554.....	18
4.3.1 Komponen yang Dikerjakan.....	18
4.3.2 Pernyataan Penggunaan AI Assistant.....	18
4.4 Zhafira Zahra Alfarisy – NPM. 2306250636.....	19
4.4.1 Komponen yang Dikerjakan.....	19

4.4.2 Pernyataan Penggunaan AI Assistant.....	19
BAB 5.....	20
5.1 Kesimpulan.....	20
5.2 Klaim Bonus Skor.....	20
DAFTAR PUSTAKA.....	21
LAMPIRAN A.....	22
LAMPIRAN B.....	23
Tautan Repositori & Dataset.....	23
APPENDIX C.....	24
Individual Consent — Member 1.....	25
Individual Consent — Member 2.....	27
Individual Consent — Member 3.....	29
Individual Consent — Member 4.....	31

DAFTAR GAMBAR

2.1	Arsitektur [nama model] (Sumber: [1])	7
2.2	Block diagram sistem yang diusulkan	8
2.3	Flowchart program training dan inference	8

DAFTAR TABEL

2.1	Ringkasan tinjauan pustaka	7
3.1	Pembagian dataset	9
3.2	Hyperparameter eksperimen	9
3.3	Hasil kuantitatif model	10

ABSTRAK

Penyakit daun tanaman tomat dapat menurunkan kualitas dan hasil panen secara signifikan apabila tidak terdeteksi sejak dini. Identifikasi manual membutuhkan waktu, ketelitian, dan pengetahuan khusus sehingga diperlukan pendekatan otomatis berbasis kecerdasan buatan. Penelitian ini mengembangkan sistem identifikasi penyakit daun tomat menggunakan pendekatan *Deep Learning* berbasis *Convolutional Neural Network* (CNN). Dataset yang digunakan adalah *PlantVillage Dataset* yang diperoleh dari Kaggle dengan total 7.223 citra dan 5 kelas penyakit daun tomat, yaitu *Tomato Early Blight*, *Tomato Late Blight*, *Tomato Leaf Mold*, *Tomato Septoria Leaf Spot*, dan *Tomato Healthy*. Tahap pra-pemrosesan meliputi *resize* citra menjadi 224×224 piksel, normalisasi piksel, *data augmentation*, serta pembagian data *training* dan validasi. Model *baseline CNN* diimplementasikan menggunakan *TensorFlow/Keras* pada *Google Colab* dengan arsitektur berupa *convolution layer*, *max pooling layer*, *dropout layer*, dan *dense layer*. Evaluasi model dilakukan menggunakan metrik *accuracy*, *loss*, *confusion matrix*, dan *classification report*. Hasil eksperimen awal menunjukkan bahwa model *baseline CNN* mampu mencapai akurasi *training* sebesar 88,74% dan akurasi validasi sekitar 92% setelah proses *training* selama 10 *epoch*. Hasil tersebut menunjukkan bahwa pendekatan CNN memiliki performa yang baik dalam klasifikasi penyakit daun tanaman berbasis citra digital dan masih berpotensi ditingkatkan lebih lanjut menggunakan metode *transfer learning MobileNetV2*.

Kata kunci: *Convolutional Neural Network*, *Deep Learning*, *PlantVillage Dataset*, Klasifikasi Citra, Penyakit Daun Tomat

BAB 1

PENDAHULUAN & DEFINISI MASALAH

1.1 Topik yang Dipilih

Topik yang dipilih adalah **Convolutional Neural Network (CNN)**, salah satu topik yang disediakan oleh tim pengajar. CNN dipilih karena sangat efektif untuk tugas klasifikasi citra, khususnya pada domain pertanian dan deteksi penyakit tanaman. Implementasi CNN pada dataset PlantVillage memungkinkan tim untuk mempelajari arsitektur jaringan saraf konvolusional secara mendalam, mulai dari baseline CNN sederhana hingga teknik transfer learning menggunakan model pretrained MobileNetV2 serta proses fine-tuning untuk meningkatkan performa klasifikasi citra penyakit tanaman. Selain itu, topik ini relevan secara praktis karena deteksi penyakit tanaman secara otomatis dapat membantu petani dalam mengidentifikasi masalah tanaman lebih cepat dan akurat. Ketersediaan dataset publik dengan jumlah data yang cukup besar juga mendukung proses pelatihan model secara optimal menggunakan Google Colab sekaligus membantu tim memahami implementasi Deep Learning dan Computer Vision pada kasus nyata.

1.2 Rumusan Masalah

1. Bagaimana performa model baseline Convolutional Neural Network (CNN) dalam mengklasifikasikan 5 jenis penyakit daun tomat menggunakan PlantVillage Dataset?
2. Apakah penggunaan metode transfer learning dan fine-tuning menggunakan MobileNetV2 dapat meningkatkan performa klasifikasi dibandingkan model baseline CNN?
3. Metrik evaluasi apa yang paling representatif untuk mengukur performa model klasifikasi penyakit daun tomat, seperti accuracy, precision, recall, F1-score, dan confusion matrix?

1.3 Tujuan Proyek

1. Menerapkan model Convolutional Neural Network (CNN) untuk mengklasifikasikan 5 kelas penyakit daun tomat menggunakan PlantVillage Dataset.
2. Mengembangkan dan melatih model baseline CNN untuk proses klasifikasi citra penyakit daun tanaman.
3. Mengimplementasikan metode transfer learning menggunakan MobileNetV2 dan melakukan fine-tuning untuk meningkatkan performa klasifikasi penyakit daun tomat.
4. Mengevaluasi performa model menggunakan metrik accuracy, precision, recall, F1-score, dan confusion matrix.

1.4 Ruang Lingkup & Batasan

Ruang Lingkup:

1. Melakukan klasifikasi 5 kelas penyakit daun tomat menggunakan *PlantVillage Dataset*.
2. Mengimplementasikan dan melatih model *baseline Convolutional Neural Network* (CNN).
3. Mengimplementasikan metode *transfer learning* menggunakan *MobileNetV2* serta melakukan *fine-tuning* pada beberapa layer terakhir model.
4. Melakukan preprocessing data dan *data augmentation* untuk meningkatkan kualitas proses training model.
5. Mengevaluasi performa model menggunakan metrik *accuracy*, *precision*, *recall*, *F1-score*, dan *confusion matrix*.
6. Mengimplementasikan model menggunakan *TensorFlow/Keras* pada lingkungan *Google Colab* dengan dukungan GPU.

Batasan Sementara:

1. Penelitian hanya menggunakan 5 kelas penyakit daun tomat dan tidak mencakup seluruh 38 kelas pada *PlantVillage Dataset*.
2. Penelitian tidak melakukan *deployment* model ke aplikasi *mobile* maupun *web*.
3. Penelitian tidak menggunakan dataset mandiri di luar *PlantVillage Dataset*.
4. Penelitian tidak melakukan evaluasi pada data *out-of-distribution* atau citra dunia nyata di luar dataset utama.
5. Penelitian tidak melakukan eksplorasi berbagai arsitektur pretrained lain selain *MobileNetV2*.
6. Penelitian tidak melakukan optimasi hyperparameter dan tuning arsitektur secara mendalam (*layer-by-layer tuning*) dan hanya menggunakan konfigurasi dasar model.
7. Seluruh eksperimen dilakukan menggunakan lingkungan *Google Colab* dengan keterbatasan sumber daya GPU gratis.

BAB 2 PENDEKATAN

AI

2.1 Tinjauan Pustaka (*Related Work*)

Tabel 2.1: Ringkasan tinjauan pustaka

Penulis (Th.)	Metode	Dataset	Hasil	Keterbatasan
Mohanty, S.P., Hughes, D.P., & Salathé, M. (2016) [3]	Membandingkan arsitektur heavyweight (AlexNet dan GoogLeNet) yang dilatih dari awal (from scratch) vs transfer learning.	PlantVillage Dataset (54.306 citra dari 14 spesies tanaman dan 26 jenis penyakit).	Mencapai akurasi ekstrem sebesar 99,35% pada kondisi pengujian laboratorium dikontrol.	Model memiliki ukuran parameter yang sangat besar, sehingga tidak efisien jika dijalankan langsung pada perangkat dengan spesifikasi perangkat keras terbatas (edge device).
Howard, A.G., et al. (2017) [4]	Memperkenalkan mekanisme Depthwise Separable Convolution untuk mengurangi beban komputasi konvolusi standar.	ImageNet dan berbagai dataset Mobile Vision benchmark.	Berhasil memangkas parameter secara drastis dengan penurunan akurasi yang sangat minimal, meletakkan dasar bagi arsitektur MobileNet.	Eksperimen berfokus pada klasifikasi objek umum berskala besar, bukan pada domain spesifik visualisasi penyakit tanaman.
Chollet, F. (2021) [5]	Menetapkan standarisasi alur kerja (best practices) implementasi Deep Learning menggunakan framework Keras/TensorFlow.	Berbagai dataset benchmark citra digital (seperti MNIST dan ImageNet).	Menyediakan metodologi validasi, teknik penanganan overfitting via Dropout, dan optimalisasi laju pembelajaran menggunakan Adam Optimizer.	Buku teks referensi bersifat panduan umum praktis arsitektur, tidak mengkaji komparasi langsung spesifik pada variasi kelas komoditas tomat.

Di saat penelitian terdahulu berfokus pada maksimasi akurasi menggunakan model berskala raksasa (seperti pada studi Mohanty dkk.) atau hanya berfokus pada teori kompresi jaringan umum (seperti studi Howard dkk.), posisi proyek kelompok kami hadir untuk menjembatani kedua aspek tersebut secara spesifik pada 5 kelas penyakit daun tomat lewat analisis komparatif langsung antara model kustom minimalis (Custom CNN) sebagai baseline berparameter rendah dengan efisiensi

transfer learning MobileNetV2.


2.2 Landasan Teori Model yang Dipilih

Penelitian ini memanfaatkan dua pendekatan arsitektur Deep Learning berbasis Convolutional Neural Network (CNN), yaitu model Custom CNN sebagai model baseline dan MobileNetV2 sebagai model utama melalui metode transfer learning.

2.2.1 Custom CNN (Baseline Model)

Convolutional Neural Network (CNN) adalah arsitektur deep learning yang dirancang khusus untuk memproses data berstruktur grid dua dimensi, seperti citra digital. Komponen utama dari arsitektur Custom CNN yang dibangun dalam proyek ini meliputi:

- **Convolutional Layer (Lapisan Konvolusi):** Merupakan inti dari arsitektur CNN yang berfungsi untuk mengekstraksi fitur spasial (seperti tepi, tekstur, dan pola bentuk) dari citra daun tomat menggunakan sejumlah filter (kernel) yang bergeser di seluruh area citra.
- **Activation Function (ReLU):** Fungsi aktivasi Rectified Linear Unit (ReLU) diterapkan setelah operasi konvolusi untuk memperkenalkan sifat non-linearitas ke dalam jaringan, sehingga model mampu mempelajari pola visual yang kompleks tanpa mengalami masalah vanishing gradient.
- **Max Pooling Layer:** Lapisan yang berfungsi untuk mereduksi dimensi spasial (downsampling) dari feature map secara lokal dengan mengambil nilai maksimum pada ukuran filter tertentu (2×2). Proses ini bertujuan untuk mengurangi beban komputasi dan menjaga sifat invariance terhadap pergeseran objek.
- **Global Average Pooling Layer & Dense Head:** Sebagai pengganti fungsi Flatten konvensional, penelitian ini menerapkan GlobalAveragePooling2D untuk mereduksi dimensi matriks fitur menjadi vektor spasial global dengan mengambil nilai rata-rata tiap kanal. Fitur tersebut dialirkan ke lapisan Dense sebesar 128 unit dengan aktivasi ReLU, diikuti oleh lapisan Dropout (0.5), dan diakhiri oleh lapisan Dense 5 unit berkekuatan fungsi Softmax untuk menghasilkan distribusi probabilitas klasifikasi penyakit daun tomat.



Gambar 2.1-1: Arsitektur CNN (Sumber: [1])


2.2.2 MobileNetV2 (Main Model)

MobileNetV2 merupakan penyempurnaan dari arsitektur CNN konvensional yang dirancang untuk efisiensi komputasi tinggi pada perangkat dengan spesifikasi terbatas. Komponen utama yang menjadi keunggulan MobileNetV2 adalah:

- **Depthwise Separable Convolution:** Operasi konvolusi yang memisahkan proses ekstraksi fitur spasial kanal per kanal (depthwise convolution) dengan proses kombinasi fitur antar kanal (pointwise convolution 1 x 1). Metode ini memangkas jumlah parameter komputasi secara signifikan dibandingkan konvolusi standar.
- **Inverted Residual Block & Linear Bottlenecks:** Struktur blok di mana dimensi kanal masukan diperluas terlebih dahulu melalui lapisan expansion, dilakukan konvolusi, dan kemudian dikompresi kembali. Jalur pintas (skip

connection) diterapkan di antara lapisan bottleneck yang tipis untuk mempermudah aliran gradien.

- **Custom Classification Head:** Di dalam penelitian ini, fitur global yang dihasilkan oleh lapisan dasar MobileNetV2 diekstrak menggunakan GlobalAveragePooling2D, kemudian disalurkan menuju lapisan Dense 128 unit (ReLU), lapisan pengendali overfitting Dropout (0.5), serta lapisan akhir Dense 5 unit (Softmax) untuk menentukan keputusan klasifikasi akhir penyakit daun tomat.



Gambar 2.1-2: Arsitektur MobileNetV2 (Sumber: [2])

2.3 Justifikasi Ilmiah Pemilihan Pendekatan AI

Pemilihan arsitektur Custom CNN (sebagai baseline) dan MobileNetV2 (sebagai model utama) didasarkan pada analisis mendalam terhadap karakteristik data citra pertanian, keterbatasan sumber daya komputasi, serta tuntutan implementasi praktis. Berikut adalah tiga poin justifikasi ilmiah utama:

2.3.1 Perbandingan Arsitektur terhadap Alternatif Lain

Dalam domain klasifikasi citra penyakit tanaman, alternatif arsitektur lain yang sering dipertimbangkan adalah model heavyweight seperti ResNet-50 atau arsitektur mutakhir berbasis Attention seperti Vision Transformer (ViT). Namun, arsitektur tersebut dinilai kurang optimal untuk kasus ini karena alasan berikut:

- **ResNet-50 vs. MobileNetV2:** Meskipun ResNet-50 memiliki kapasitas ekstraksi yang besar berkat residual connections, jumlah parameternya sangat membengkak mencapai 25 juta. Sebaliknya, MobileNetV2 yang diintegrasikan dengan classification head kustom pada penelitian ini hanya memiliki sekitar 3,5 juta parameter. Menggunakan ResNet-50 pada dataset berukuran moderat (7.223 sampel) memiliki risiko tinggi memicu overfitting yang parah, di mana model rentan menghafal derau (noise) pada latar belakang gambar daun laboratoris ketimbang fitur patologisnya.
- **Vision Transformer (ViT) vs. CNN:** ViT tidak memiliki inductive bias bawaan seperti karakteristik translation invariance dan locality yang dimiliki oleh CNN. Akibatnya, ViT membutuhkan ratusan ribu hingga jutaan data latihan agar dapat melakukan konvergensi dengan baik. Untuk skala PlantVillage Dataset versi tomat yang digunakan, pendekatan berbasis konvolusi (CNN) jauh lebih superior dan efisien dalam mengekstraksi fitur lokal yang krusial seperti bercak nekrotik kecil (pada Septoria) atau batas lesi cincin (pada Target Spot).

2.3.2 Analisis Tradeoff (Akurasi vs. Kecepatan vs. Ukuran Model)

Keputusan untuk menggunakan kombinasi Custom CNN dan MobileNetV2 dilandasi oleh pertimbangan kompromi (tradeoff) yang matang demi mengejar klaim Bonus B1 (analisis komparatif):

- **Akurasi vs. Ukuran Model:** Model Custom CNN dirancang seminimal mungkin menggunakan 3 blok konvolusi untuk menetapkan batas bawah (baseline) akurasi. Ketika menginjak model utama, MobileNetV2 dipilih karena menggunakan struktur Depthwise Separable Convolution. Operasi ini memisahkan ekstraksi spasial kanal demi kanal (depthwise) dan kombinasi antar kanal (pointwise 1 x 1), sehingga mampu memangkas parameter secara drastis tanpa mengorbankan kapasitas representasi fitur. Hasilnya, model tetap mampu menghasilkan akurasi tinggi dengan ukuran berkas model yang sangat ringkas.
- **Kecepatan Training vs. Batasan Hardware:** Mengingat proses eksperimen dilakukan pada lingkungan cloud Google Colab dengan batasan alokasi waktu GPU (T4), ukuran MobileNetV2 yang ringan memastikan waktu komputasi per epoch berjalan sangat cepat. Efisiensi ini membuka ruang bagi tim untuk melakukan hyperparameter tuning secara fleksibel demi mendapatkan performa terbaik dalam batasan waktu yang ada.

2.3.3 Konteks Domain Spesifik yang Membuat Pilihan Ini Superior


Karakteristik visual dari penyakit daun tomat sangat bergantung pada detail tekstur lokal, tingkat degradasi warna (klorosis), dan geometri lesi mikro pada permukaan daun.

- Operasi konvolusi 2D pada Custom CNN dan MobileNetV2 bekerja menyerupai filter pemrosesan citra spasial lokal yang sangat sensitif terhadap perubahan gradien warna dan bentuk bercak daun tersebut.
- Konteks domain aplikasi nyata dari sistem ini dirancang untuk dapat diintegrasikan ke dalam perangkat mobile atau edge device (misalnya aplikasi smartphone milik petani di lapangan). Oleh karena itu, arsitektur MobileNetV2 menjadi pilihan yang paling superior secara kontekstual, karena model yang dihasilkan memiliki ukuran file yang kecil (beberapa megabyte) dan latency inferensi yang sangat rendah, sehingga memungkinkannya berjalan secara real-time tanpa memerlukan koneksi internet aktif ke server berspesifikasi tinggi.

2.4 *Block Diagram Sistem End-to-End*

Sistem identifikasi penyakit daun tomat dalam proyek ini dirancang secara terintegrasi dari tahap masukan data mentah hingga menghasilkan metrik evaluasi akhir. Alur kerja end-to-end (ujung-ke-ujung) dari sistem ini dibagi menjadi enam tahapan utama:

1. **Data Input:** Proses dimulai dari pemuatan citra mentah daun tomat (Tomato Leaf Disease) dari PlantVillage Dataset yang diakses melalui lingkungan Google Colab.
2. **Preprocessing Pipeline:** Citra mentah masuk ke dalam fungsi ImageDataGenerator untuk melewati proses pemangkasan dimensi (resizing) menjadi 224 x 224 piksel, normalisasi nilai intensitas piksel (rescale=1./255), serta pembagian subset data (validation split 20%). Proses augmentasi data fungsional (seperti rotation, shear, zoom, dan horizontal flip) hanya diaplikasikan secara spesifik pada data latihan (training set) untuk menambah variasi sampel tanpa mengubah karakteristik data validasi.
3. **Model Architecture:** Data yang telah melewati pipeline prapemrosesan dialirkan menuju salah satu blok arsitektur model terpilih yang diuji secara komparatif, yaitu model Custom CNN (menggunakan kombinasi layer konvolusi, max pooling, dan Global Average Pooling) atau model utama MobileNetV2 (Transfer Learning ImageNet) menggunakan ukuran kelompok penyaluran data yang seragam (Batch Size = 32).
4. **Loss Computation:** Saat proses training, luaran prediksi dari model akan dihitung tingkat kesalahannya menggunakan fungsi kerugian Categorical Cross-Entropy Loss untuk mengoptimalkan proses pembaruan bobot (weights update) melalui algoritma Adam Optimizer.
5. **Performance Metrics:** Evaluasi performa model diukur secara komparatif menggunakan metrik kuantitatif utama, yaitu tingkat akurasi (Accuracy), skor keseimbangan presisi (F1-Score), serta grafik riwayat latihan (Training/Validation Loss and Accuracy Curves).
6. **System Output:** Luaran akhir dari sistem ini adalah visualisasi matriks kesalahan (Confusion Matrix) serta hasil inferensi prediksi label kategori dari 5 jenis kelas penyakit daun tomat yang akurat.



Gambar 2.4-1: Block diagram sistem


2.5 Flowchart Program

Alur eksekusi (runtime) program dalam proyek ini dibagi menjadi dua proses utama yang berjalan secara terpisah namun saling berkesinambungan, yaitu alur Proses Training (pembelajaran model) dan alur Proses Inference (prediksi penyakit pada data citra baru).

- 1. Alur Runtime Training:** Proses dimulai dengan memuat PlantVillage Dataset dari Google Drive ke Google Colab, dilanjutkan dengan proses resizing (224 x 224), normalisasi skala piksel, dan augmentasi data gambar. Data kemudian dipecah menjadi Training Set (80%) dan Validation Set (20%). Model (Custom CNN atau

MobileNetV2) memproses gambar dalam ukuran kelompok (Batch Size = 32), menghitung Categorical Cross-Entropy Loss, dan memperbarui bobot menggunakan Adam Optimizer. Jika target iterasi (Epoch = 10) telah tercapai, grafik performa akan divisualisasikan dan bobot model terbaik akan disimpan secara permanen sebagai file berkas .h5 atau .keras.

2. **Alur Runtime Inference:** Proses ini berjalan ketika pengguna memasukkan selembaar citra daun tomat baru yang belum pernah dilihat oleh model. Program akan memuat berkas bobot model yang telah disimpan sebelumnya. Citra masukan baru tersebut harus melalui tahap preprocessing yang identik (resizing ke 224 x 224 dan rescale 1./255). Model kemudian melakukan forward pass untuk menghasilkan distribusi probabilitas kelas menggunakan fungsi Softmax. Program akan mengekstrak indeks dengan nilai probabilitas tertinggi (Argmax) untuk menghasilkan output final berupa label prediksi teks 1 dari 5 kategori penyakit tanaman tomat.



Gambar 2.5-1: Flowchart program training dan inference

BAB 3

IMPLEMENTASI & HASIL EKSPERIMEN

3.1 Dataset & Pra-pemrosesan

Dataset yang digunakan pada penelitian ini adalah **PlantVillage Dataset** yang diperoleh secara publik melalui Kaggle. Dataset tersebut berisi citra daun tanaman dengan berbagai jenis penyakit serta kondisi daun sehat. Pada penelitian ini, dataset difokuskan pada **5 kelas penyakit daun tomat** untuk menjaga efisiensi proses training model dan menyesuaikan keterbatasan sumber daya komputasi pada lingkungan Google Colab dengan dukungan GPU.

Implementasi klasifikasi citra dilakukan menggunakan pendekatan **Deep Learning berbasis Convolutional Neural Network (CNN)** dan **transfer learning MobileNetV2** menggunakan framework **TensorFlow/Keras** pada lingkungan **Google Colab**.

Lima kelas dataset yang digunakan pada penelitian ini terdiri atas:


1. *Tomato Early Blight*
2. *Tomato Late Blight*
3. *Tomato Leaf Mold*
4. *Tomato Septoria Leaf Spot*
5. *Tomato Healthy*

Dataset terdiri dari total 7.223 citra dengan ukuran input sebesar 224×224 piksel. Sebelum digunakan pada proses training model, dilakukan tahap pra-pemrosesan data untuk menyesuaikan format input model dan meningkatkan kualitas proses pembelajaran.

Tahap pra-pemrosesan yang dilakukan meliputi:

- Resize citra menjadi 224×224 piksel
- Normalisasi piksel menggunakan $\text{rescale} = 1./255$
- Data augmentation berupa:
 - $\text{rotation_range} = 20$
 - $\text{horizontal_flip} = \text{True}$
 - $\text{zoom_range} = 0.2$

Teknik data augmentation digunakan untuk meningkatkan variasi data training sehingga model menjadi lebih robust dan mampu mengurangi risiko overfitting selama proses training. Selain itu, dataset dibagi menggunakan metode **train-validation split** dengan rasio **80:20** menggunakan parameter `validation_split = 0.2`. Berdasarkan hasil pembagian data, diperoleh sebanyak **5.780 citra training** dan **1.443 citra validation**. Untuk menjaga konsistensi hasil eksperimen, digunakan `seed = 42` pada proses pembagian dataset dan augmentasi data.



Gambar 3.1 Visualisasi Sampel Dataset PlantVillage

Tabel 3.1: Pembagian dataset

Subset	Jumlah Sampel	Rasio (%)
Training	5.780	80%
Validation	1.443	20%
Test	—	—
Total	7.223	100%

3.2 Konfigurasi Eksperimen


Eksperimen pada penelitian ini dilakukan menggunakan framework **TensorFlow/Keras** pada lingkungan **Google Colab dengan dukungan GPU** untuk mempercepat proses training model. Penelitian menggunakan dua pendekatan utama, yaitu **baseline Convolutional Neural Network**

(CNN) dan transfer learning MobileNetV2.

Model baseline CNN digunakan sebagai model awal untuk mengetahui performa dasar klasifikasi citra sebelum dilakukan pengembangan lebih lanjut menggunakan MobileNetV2. Arsitektur baseline CNN dibangun menggunakan beberapa convolution layer, max pooling layer, dropout layer, dan dense layer dengan fungsi aktivasi **ReLU** pada hidden layer dan **Softmax** pada output layer.

Sementara itu, MobileNetV2 digunakan sebagai model transfer learning karena memiliki jumlah parameter yang relatif ringan dibandingkan beberapa arsitektur pretrained lainnya sehingga lebih sesuai digunakan pada lingkungan Google Colab gratis. Selain itu, MobileNetV2 juga memiliki performa yang baik untuk tugas klasifikasi citra dengan ukuran dataset menengah dan efisiensi komputasi yang baik.

Selain menggunakan pretrained weight dari ImageNet, dilakukan juga proses **fine-tuning** pada sekitar **30 layer terakhir MobileNetV2** untuk meningkatkan kemampuan model dalam mengenali fitur penyakit daun secara lebih spesifik. Fine-tuning dilakukan dengan membuka kembali sebagian layer pretrained agar model dapat menyesuaikan parameter terhadap karakteristik dataset PlantVillage.



Gambar 3.2 Arsitektur Baseline CNN

Pada proses training, digunakan optimizer **Adam** dengan fungsi loss `categorical_crossentropy` karena penelitian ini termasuk ke dalam permasalahan **multi-class classification**. Optimizer Adam dipilih karena mampu melakukan penyesuaian learning rate secara adaptif sehingga proses training menjadi lebih stabil dan cepat konvergen.

Selain itu, digunakan callback `ReduceLROnPlateau` untuk menurunkan learning rate secara otomatis ketika performa validation tidak mengalami peningkatan dalam beberapa epoch tertentu sehingga proses training menjadi lebih stabil. Penelitian ini juga menggunakan callback `EarlyStopping` dan `ModelCheckpoint` untuk membantu mencegah overfitting serta menyimpan model terbaik selama proses training berlangsung.

Seluruh eksperimen dilakukan menggunakan ukuran input citra sebesar **224×224 piksel**, batch size sebesar **32**, dan jumlah epoch sebanyak **10 epoch**. Selain itu, penelitian juga menerapkan teknik **dropout sebesar 0.5** untuk membantu mengurangi risiko overfitting dengan cara menonaktifkan sebagian neuron secara acak selama proses training.

Evaluasi performa model dilakukan menggunakan beberapa metrik, yaitu **accuracy**, **loss**, **precision**, **recall**, **F1-score**, serta **confusion matrix** untuk mengetahui kemampuan klasifikasi model pada masing-masing kelas penyakit daun tomat.

Tabel 3.2: Hyperparameter eksperimen

Hyperparameter	Nilai
Learning rate	0.001
LR fine-tuning	0.00001
Batch size	32
Epoch	10
Optimizer	Adam
Scheduler	ReduceLROnPlateau
Callbacks	EarlyStopping, ModelCheckpoint
Loss function	<code>categorical_crossentropy</code>
Activation function	<i>ReLU dan Softmax</i>
Dropout rate	0.5
Input image size	224x224
Random seed	42
Framework	<i>TensorFlow/Keras</i>
Environment	Google Colab GPU

3.3 Metrik Evaluasi

Evaluasi performa model pada penelitian ini dilakukan menggunakan beberapa metrik, yaitu *accuracy*, *F1-score*, *confusion matrix*, dan *loss*. Metrik *accuracy* digunakan untuk mengukur persentase prediksi yang benar terhadap seluruh data yang diuji sehingga dapat memberikan gambaran umum performa model klasifikasi. Selain itu, *loss* digunakan untuk mengukur tingkat kesalahan model selama proses *training* dan validasi.

Penelitian ini juga menggunakan *F1-score* karena metrik tersebut mampu memberikan evaluasi yang lebih seimbang antara *precision* dan *recall*, khususnya pada klasifikasi multikelas (*multi-class classification*). Sementara itu, *confusion matrix* digunakan untuk melihat distribusi prediksi model pada setiap kelas penyakit daun tomat dan membantu proses analisis kesalahan klasifikasi (*error analysis*). Kombinasi beberapa metrik evaluasi tersebut diharapkan mampu memberikan gambaran performa model secara lebih komprehensif dibandingkan hanya menggunakan *accuracy* saja.


3.4 Hasil Kuantitatif

Hasil kuantitatif dari model baseline CNN dan model MobileNetV2 fine-tuned yang dievaluasi pada data validasi sebanyak 1.443 sampel dengan konfigurasi kondisi tanpa augmentasi, *shuffle*=False, dan *seed*=42. Berdasarkan grafik riwayat pelatihan model baseline CNN, terlihat tren peningkatan *accuracy* yang stabil sepanjang 10 epoch, dimulai dari epoch 1 dengan training *accuracy* sebesar 55,00% dan validation *accuracy* 63,55%, hingga mencapai puncaknya pada epoch 9 dengan training *accuracy* 89,62% dan validation *accuracy* tertinggi sebesar 93,14%. Di samping itu, sempat terjadi lonjakan validation *accuracy* yang cukup signifikan pada epoch 6 dari nilai 86,35% menjadi 89,81%. Penurunan kurva *loss* yang konsisten baik pada data training maupun validasi mengindikasikan bahwa model baseline CNN dapat

Tabel 3.3: Hasil kuantitatif model


Konfigurasi	Train	Val	Test
Baseline CNN	89,78%	81,08%	–
Proposed (MobileNetV2)	93,94%	92,24%	–

Evaluasi performa klasifikasi baseline CNN per kelas menunjukkan hasil yang bervariasi; kelas Healthy berhasil mendapatkan nilai recall tertinggi sempurna sebesar 1,0000 yang menandakan seluruh sampel daun sehat berhasil diprediksi dengan benar oleh model. Sebaliknya, performa terendah dicatatkan oleh kelas Leaf Mold dengan nilai recall sebesar 0,6421 serta kelas Early Blight dengan nilai precision terendah sebesar 0,6215. Secara akumulatif, model baseline CNN ini menghasilkan total accuracy sebesar 81,08%, dengan nilai weighted F1-score sebesar 0,8078, dan macro F1-score sebesar 0,7950.



Gambar 3.3 Precision, Recall, dan F1-Score per Kelas Baseline CNN


MobileNetV2 fine-tuned secara konsisten melampaui capaian baseline CNN pada seluruh metrik evaluasi utama. Model ini sukses meningkatkan akurasi total sebesar +11,16% (dari 81,08% menjadi 92,24%), meningkatkan weighted F1-score sebesar +0,1124 (dari 0,8078 menjadi 0,9201), serta kenaikan macro F1-score sebesar +0,1125 (dari 0,7950 menjadi 0,9075) yang membuktikan bahwa penerapan metode transfer learning memberikan dampak yang sangat krusial dalam mengoptimalkan klasifikasi penyakit daun tomat melampaui target akurasi 90%



Gambar 3.4 Perbandingan Accuracy, Weighted F1, dan Macro F1


3.5 Analisis *Hyperparameter Tuning*

Proses hyperparameter tuning pada penelitian ini dilakukan menggunakan metode Manual Heuristic Tuning (pendekatan trial-error berbasis teori arsitektur) melalui strategi Two-Phase Transfer Learning pada model MobileNetV2, alih-alih menggunakan pencarian otomatis seperti Grid atau Bayesian Search. Dokumentasi perkembangan metrik akurasi dan loss terhadap kombinasi hyperparameter kunci ini direkam secara berkala sepanjang 20 epoch total pelatihan, yang terbagi ke dalam Fase 1 (Feature Extraction) and Fase 2 (Fine-tuning). Konfigurasi hyperparameter kunci yang dieksperimenkan meliputi perubahan learning rate dari $10^{-4} \rightarrow 10^{-5}$, tingkat dropout rate (0.5), serta jumlah layer terlarang yang dibuka kuncinya (unfrozen layers) pada base model.




Gambar 3.4 Grafik Training dan Validation Accuracy & Loss

Hyperparameter yang ditemukan paling sensitif terhadap performa model adalah Learning Rate dan Jumlah Unfrozen Layers. Pada Fase 1, penggunaan learning rate 10^{-4} dengan seluruh base layer dibekukan (frozen) berhasil meningkatkan akurasi validasi secara cepat dari 76,99% menjadi 91,68%. Namun, saat memasuki Fase 2, ketika 30 layer terakhir mulai dibuka, model terbukti sangat sensitif terhadap nilai learning rate; penggunaan nilai yang terlalu tinggi berisiko merusak bobot pra-latih pretrained ImageNet catastrophic forgetting. Oleh karena itu, penurunan learning rate menjadi lebih kecil 10^{-5} pada Fase 2 terbukti menjadi keputusan tuning yang krusial untuk menjaga kestabilan pelatihan hingga mencapai akurasi validasi akhir sebesar 92,24%. Sementara itu, penggunaan komponen Dropout 0.5 dan teknik scheduler ReduceLROnPlateau bertindak sebagai parameter penunjang yang efektif menjaga kurva agar terhindar dari overfitting.



Gambar 3.5 Error Rate per Kelas MobileNetV2 Fine-tuned




Gambar 3.6 Distribusi Confidence Score pada Prediksi Benar vs Salah

3.6 Hasil Kualitatif & Error Analysis

Hasil eksperimen menunjukkan bahwa model baseline CNN mampu melakukan klasifikasi penyakit daun tomat dengan performa yang cukup baik pada sebagian besar kelas dataset. Evaluasi dilakukan menggunakan metrik accuracy, loss, confusion matrix, dan classification report. Berdasarkan hasil prediksi model, kelas Healthy berhasil diklasifikasikan dengan sempurna (recall = 1.0000) dengan seluruh 318 sampel terprediksi benar. Kelas Septoria Leaf Spot juga menunjukkan performa yang baik dengan 329 dari 354 sampel terprediksi benar (recall = 0.9294).

Meskipun demikian, model masih mengalami kesalahan prediksi yang cukup signifikan pada beberapa kelas. Kelas Late Blight paling banyak mengalami misklasifikasi, di mana 67 dari 381 sampel diprediksi sebagai Early Blight dan 52 sampel diprediksi sebagai Healthy, sehingga menghasilkan recall hanya 0.6430. Kelas Early Blight juga mengalami banyak kesalahan, di mana 37 sampel diprediksi sebagai Healthy. Kelas Leaf Mold sering salah diprediksi sebagai Septoria Leaf Spot dengan jumlah kesalahan sebanyak 43 sampel, menghasilkan recall sebesar 0.6421. Kesalahan-kesalahan tersebut diduga terjadi karena kemiripan pola bercak dan degradasi warna pada daun antar kelas yang berdekatan secara visual, serta variasi pencahayaan dan kualitas citra pada dataset.

Berikut adalah confusion matrix aktual dari model Baseline CNN pada data validasi (1.443 sampel):



Gambar 3.5 Confusion Matrix Baseline CNN

Setelah dilatih dengan MobileNetV2 Fine-tuned, performa per kelas meningkat secara signifikan. Classification report MobileNetV2 menunjukkan peningkatan F1-score pada seluruh kelas dibandingkan baseline, dengan rincian sebagai berikut: Early Blight meningkat dari 0.6918 menjadi 0.7919, Late Blight meningkat dari 0.7778 menjadi 0.9372, Leaf Mold meningkat dari 0.7625 menjadi 0.8931, Septoria Leaf Spot meningkat dari 0.8844 menjadi 0.9335, dan Healthy meningkat dari 0.8583 menjadi 0.9815. Peningkatan terbesar terjadi pada kelas Late Blight dan Leaf Mold, yang merupakan kelas dengan tingkat kesalahan tertinggi pada model baseline.

Untuk mengurangi kesalahan klasifikasi, penelitian ini menggunakan teknik data augmentation dan dropout layer guna meningkatkan variasi data serta mengurangi risiko overfitting. Penggunaan strategi two-phase training pada MobileNetV2 terbukti efektif dalam meningkatkan kemampuan generalisasi model secara signifikan.

3.7 Pembahasan

Berdasarkan hasil eksperimen yang telah dilakukan, model baseline Convolutional Neural Network (CNN) mampu melakukan klasifikasi penyakit daun tomat dengan akurasi validasi sebesar 81.08% setelah proses training selama 10 epoch. Meskipun val_accuracy sempat mencapai 93.14% pada epoch 9, hasil evaluasi akhir menggunakan classification_report yang lebih representatif menunjukkan angka 0.8108 karena proses evaluasi dilakukan pada subset validasi tanpa augmentasi secara konsisten. Dengan demikian, rumusan masalah pertama terkait performa baseline CNN dalam mengklasifikasikan penyakit daun tomat dapat dijawab melalui hasil eksperimen yang diperoleh.

Terkait rumusan masalah kedua, penggunaan metode transfer learning MobileNetV2 terbukti meningkatkan performa klasifikasi secara signifikan dibandingkan model baseline CNN. Peningkatan accuracy sebesar +11.16% (dari 0.8108 menjadi 0.9224) dan Macro F1 sebesar +11.25% (dari 0.7950 menjadi 0.9075) mengkonfirmasi bahwa fitur visual yang dipelajari dari ImageNet sangat relevan dan dapat ditransfer secara efektif ke domain klasifikasi citra penyakit daun tomat. Strategi dua fase training, yaitu feature extraction diikuti fine-tuning pada 30 layer terakhir, terbukti lebih optimal dibandingkan melatih model dari awal (from scratch) pada skala dataset yang digunakan.

Selain itu, penggunaan metrik evaluasi seperti accuracy, F1-score, dan confusion matrix memberikan gambaran performa model yang lebih komprehensif. Berdasarkan hasil confusion matrix, tantangan utama klasifikasi terletak pada kelas-kelas dengan karakteristik visual yang serupa, khususnya Late Blight dan Early Blight, serta Leaf Mold dan Septoria Leaf Spot. Hal tersebut menunjukkan bahwa kemiripan pola bercak daun masih menjadi tantangan yang perlu diatasi melalui pendekatan arsitektur yang lebih mendalam.

Penelitian ini masih memiliki beberapa keterbatasan, antara lain belum digunakannya data test terpisah sehingga evaluasi dilakukan sepenuhnya pada data validasi, proses hyperparameter tuning yang masih terbatas pada konfigurasi dasar, serta belum dilakukannya evaluasi pada citra dunia nyata di luar PlantVillage Dataset. Untuk pengembangan berikutnya, penelitian dapat ditingkatkan melalui penambahan data test terpisah, eksplorasi teknik interpretabilitas seperti Grad-CAM untuk memahami fitur yang dipelajari model, serta implementasi model ke aplikasi berbasis web atau mobile agar dapat digunakan secara praktis dalam proses identifikasi penyakit tanaman di lapangan.

BAB 4

PEMBAGIAN TUGAS & DEKLARASI KONTRIBUSI INDIVIDUAL

4.1 Nabiel Harits Utomo – NPM. 2306267044

4.1.1 Komponen yang Dikerjakan

Daftar konkret bagian proyek yang menjadi tanggung jawab penuh saya:

- **Kode/modul:** Implementasi notebook CNN, *preprocessing pipeline*, *evaluation pipeline*, visualisasi *accuracy/loss*, *confusion matrix*, evaluasi performa model, serta penyusunan *metadata.json* proyek.
- **Bagian arsitektur:** Implementasi *image preprocessing*, pengelolaan dataset *PlantVillage*, workflow evaluasi model CNN menggunakan *TensorFlow/Keras*, serta analisis hasil *baseline CNN* dan *MobileNetV2*.
- **Bagian analisis:** Analisis *accuracy*, *loss visualization*, *confusion matrix*, validasi performa model CNN, dan evaluasi hasil klasifikasi citra penyakit daun tomat.
- **Bagian laporan:** Bagian Evaluasi, *Error Analysis*, Bab 2 dan Bab 4 (*Pembagian Tugas & Deklarasi Kontribusi Individual*).

4.1.2 Pernyataan Penggunaan AI Assistant

- **Tool yang dipakai:** Gemini 3 Flash & ChatGPT 5.5
- **Untuk bagian apa:** Membantu validasi struktur *metadata JSON*, evaluasi dokumentasi proyek, analisis hasil eksperimen CNN, dan review penyusunan laporan teknis.
- **Tingkat ketergantungan:** Rendah (estimasi $\pm 20\%$ output berasal dari AI)
- **Pernyataan:** Saya memahami dan dapat mempertanggungjawabkan setiap baris kode/teks yang saya klaim sebagai bagian saya.

4.2 Muhammad Pavel – NPM. 2306242363

4.2.1 Komponen yang Dikerjakan

- **Kode/modul:** Implementasi notebook CNN, konfigurasi *training workflow*, monitoring proses *training*, pengelolaan struktur repository proyek, optimasi *baseline CNN*, serta eksplorasi *transfer learning MobileNetV2*.

- **Bagian arsitektur:** Implementasi *baseline CNN*, konfigurasi *training model* menggunakan *TensorFlow/Keras*, serta eksplorasi arsitektur *MobileNetV2* untuk klasifikasi citra penyakit daun tomat.
- **Bagian analisis:** Analisis proses *training model*, validasi eksperimen awal, evaluasi performa *baseline CNN*, serta perbandingan hasil model CNN dan *MobileNetV2*.
- **Bagian laporan:** Bab 2 (*Deskripsi Dataset*) dan Bab 3 (*Metodologi Implementasi*).

4.2.2 Pernyataan Penggunaan AI Assistant

- **Tool yang dipakai:** Gemini 3 Flash & Claude Sonnet 4.6
- **Untuk bagian apa:** Berdiskusi terkait *workflow training CNN*, validasi struktur repository proyek, eksplorasi *MobileNetV2*, dan review laporan.
- **Tingkat ketergantungan:** Rendah (estimasi $\pm 20\%$ output berasal dari AI)
- **Pernyataan:** Saya memahami dan dapat mempertanggungjawabkan setiap baris kode/teks yang saya klaim sebagai bagian saya.

4.3 R. Aisha Syauqi Ramadhani – NPM. 2306250554

4.3.1 Komponen yang Dikerjakan

- **Kode/modul:** Implementasi notebook CNN, dokumentasi *preprocessing*, visualisasi dataset, dokumentasi eksperimen awal, dan penyusunan README proyek.
- **Bagian arsitektur:** Membantu implementasi workflow *preprocessing*, visualisasi dataset, dan pengelolaan dokumentasi eksperimen pada notebook CNN.
- **Bagian analisis:** Review hasil *preprocessing*, visualisasi dataset, dokumentasi eksperimen awal, dan validasi tahapan *data augmentation*.
- **Bagian laporan:** Bagian Dataset, *Preprocessing*, BAB 1, Bab 3 serta dokumentasi teknis proyek dan README repository.

4.3.2 Pernyataan Penggunaan AI Assistant

- **Tool yang dipakai:** ChatGPT Go
- **Untuk bagian apa:** Membantu analisis dataset yang digunakan, optimasi

preprocessing pipeline, dan review dokumentasi proyek.

- **Tingkat ketergantungan:** Rendah (estimasi $\pm 20\%$ output berasal dari AI)
- **Pernyataan:** Saya memahami dan dapat mempertanggungjawabkan setiap baris kode/teks yang saya klaim sebagai bagian saya.

4.4 Zhafira Zahra Alfarisy – NPM. 2306250636

4.4.1 Komponen yang Dikerjakan

- **Kode/modul:** Implementasi notebook CNN, pengelolaan dataset *training*, *dataset loading*, visualisasi hasil *training model*, serta *evaluation visualization*.
- **Bagian arsitektur:** Pengelolaan struktur dataset *PlantVillage*, eksplorasi arsitektur CNN, dan analisis hasil *training model* CNN dan *MobileNetV2*.
- **Bagian analisis:** Analisis struktur dataset, validasi hasil *training model*, visualisasi *loss/accuracy*, serta evaluasi hasil klasifikasi citra penyakit daun tomat.
- **Bagian laporan:** Bab 1, Bab 3, Hasil Sementara, dan dokumentasi visualisasi hasil eksperimen.

4.4.2 Pernyataan Penggunaan AI Assistant

- **Tool yang dipakai:** Claude Sonnet 4.6
- **Untuk bagian apa:** Membantu diskusi evaluasi *baseline CNN*, visualisasi metrik performa, analisis hasil *training*, dan review eksperimen model klasifikasi.
- **Tingkat ketergantungan:** Rendah (estimasi $\pm 20\%$ output berasal dari AI)
- **Pernyataan:** Saya memahami dan dapat mempertanggungjawabkan setiap baris kode/teks yang saya klaim sebagai bagian saya.

BAB 5

KESIMPULAN & PEKERJAAN LANJUTAN

5.1 Kesimpulan

1. Model baseline CNN berhasil melakukan klasifikasi 5 kelas penyakit daun tomat menggunakan PlantVillage Dataset dengan validation accuracy sebesar **89.81%** dan validation loss sebesar **0.267** setelah training selama 10 epoch.
2. Penggunaan transfer learning MobileNetV2 meningkatkan performa model menjadi accuracy sebesar **92.24%**, weighted F1-score sebesar **0.9201**, dan macro F1-score sebesar **0.9075**, sehingga memberikan hasil yang lebih baik dibandingkan baseline CNN.
3. Kelas **Healthy** memiliki performa terbaik dengan recall mencapai **100%**, sedangkan kelas **Early Blight** memiliki error rate tertinggi sebesar **31.5%** akibat kemiripan visual dengan kelas penyakit lain seperti Septoria Leaf Spot dan Leaf Mold.
4. Tahap preprocessing seperti resize citra, normalisasi piksel, dan data augmentation membantu meningkatkan stabilitas training dan mengurangi risiko overfitting selama proses pembelajaran model.
5. Secara keseluruhan, pendekatan CNN dan transfer learning MobileNetV2 menunjukkan potensi yang baik untuk dikembangkan sebagai sistem identifikasi penyakit tanaman berbasis citra digital secara otomatis.

5.2 Klaim Bonus Skor

☒ **B1. Evaluasi Komparatif & Iterasi** → bukti pada Subbab 3.4 dan 3.5

Bukti Objektif: Terlampir secara komparatif pada Subbab 3.4 dan Subbab 3.5.

Deskripsi Pendukung: Penelitian ini secara eksplisit membandingkan kinerja model baseline Custom CNN (yang dilatih dari awal/from scratch) dengan model utama berbasis transfer learning MobileNetV2 menggunakan bobot pre-trained ImageNet. Evaluasi komparatif disajikan melalui metrik kuantitatif (Accuracy, F1-Score, dan matriks konvergensi Loss/Accuracy) untuk melihat signifikansi peningkatan performa arsitektur AI yang dipilih.

☐ **B2. Dataset Mandiri** → bukti pada Subbab 3.1 + Lampiran B

☒ **B3. Analisis Etika, Bias, & Keterbatasan** → bukti pada Subbab 3.7

Bukti Objektif: Terlampir secara komprehensif pada Subbab 3.7 (Pembahasan).

Deskripsi Pendukung: Dokumen ini memuat analisis mendalam mengenai keterbatasan eksperimen yang dijalankan. Hal ini mencakup dependensi pemisahan dataset berbasis fitur internal (`validation_split`), analisis bias visual (`confounding factors`) akibat kondisi pencahayaan dan latar belakang laboratorium terkontrol pada PlantVillage Dataset, serta tantangan generalisasi model apabila diimplementasikan langsung pada citra dunia nyata (*in-the-wild*) untuk kebutuhan praktis para petani di lapangan.

5.3 Pekerjaan Lanjutan (*Future Work*)

1. Implementasi Modul Interpretabilitas Menggunakan Grad-CAM (Gradient-weighted Class Activation Mapping)

Untuk mengatasi sifat black-box dari model Deep Learning, pengembangan berikutnya perlu menambahkan visualisasi Grad-CAM pada arsitektur MobileNetV2. Modul ini bertujuan untuk memetakan area piksel atau wilayah spasial pada daun tomat yang menjadi fokus utama perhatian (*attention*) model saat mengekstraksi fitur penyakit (misalnya deteksi letak bintik Septoria vs struktur urat daun), sehingga hasil keputusan prediksi menjadi lebih akuntabel dan mudah diinterpretasikan secara agronomis.

2. Evaluasi Reliabilitas Model pada Dataset Out-of-Domain Realistis (In-the-Wild)

Mengingat PlantVillage Dataset memiliki karakteristik latar belakang gambar yang sangat seragam dan steril (kondisi laboratorium), model perlu diuji menggunakan citra out-of-domain baru yang diambil langsung dari lahan pertanian nyata. Dataset pengujian tambahan ini harus mencakup variasi pencahayaan alami yang ekstrem (terik matahari/mendung), sudut pengambilan gambar yang dinamis, serta gangguan latar belakang (*noise background*) seperti struktur tanah, gulma, atau bayangan tanaman lain.

3. Restrukturisasi Data Pipeline Menggunakan Skema Hold-out Test Set yang Terisolasi secara Absolut

Pengembangan dari sisi metodologi perlu memperbaiki penanganan data dengan memisahkan sebagian subset data (misalnya 10% s.d. 15% dari total 7.223 sampel) sebagai Hold-out Test Set mandiri yang benar-benar terisolasi sebelum fungsi pipeline pelatihan dimulai. Hal ini penting untuk menggantikan ketergantungan pada argumen `internal_validation_split=0.2` bawaan, guna menjamin pengujian performa akhir model yang lebih objektif dan bebas dari isu kebocoran data (data leakage).

4. Optimalisasi Kompresi Model Menggunakan Teknik Post-Training Quantization (PTQ) untuk Penyebaran pada Edge Device

Agar model utama MobileNetV2 dapat diintegrasikan secara praktis ke dalam aplikasi perangkat mobile milik petani tanpa membebani memori, pekerjaan lanjutan dapat menerapkan teknik Quantization melalui TensorFlow Lite. Proses ini akan mengonversi bobot parameter model dari format float32 menjadi int8, sehingga mampu memangkas ukuran file model (menjadi beberapa megabyte saja) serta menekan latency waktu inferensi tanpa mendegradasi akurasi secara signifikan.

DAFTAR PUSTAKA

- [1] Y. LeCun, L. Bottou, Y. Bengio, and P. Haffner, "Gradient-based learning applied to document recognition," *Proceedings of the IEEE*, vol. 86, no. 11, pp. 2278–2324, Nov. 1998.
- [2] M. Sandler, A. Howard, M. Zhu, A. Zhmoginov, and L.-C. Chen, "MobileNetV2: Inverted Residuals and Linear Bottlenecks," in *Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition (CVPR)*, 2018, pp. 4510–4520.
- [3] Mohanty, S.P., Hughes, D.P., & Salathé, M. (2016). Using Deep Learning for Image-Based Plant Disease Detection. *Frontiers in Plant Science*. Insight: Paper foundational yang memperkenalkan PlantVillage Dataset dan menunjukkan CNN dapat mencapai akurasi >99% pada kondisi lab.
- [4] Howard, A.G., et al. (2017). *MobileNets: Efficient Convolutional Neural Networks for Mobile Vision Applications*. arXiv. Insight: Menjadi dasar pemilihan MobileNetV2 sebagai model transfer learning karena efisiensinya pada perangkat terbatas.
- [5] Chollet, F. (2021). *Deep Learning with Python*. Manning Publications.

LAMPIRAN A

Berkas Metadata Proyek (JSON)

```
{
  "kode_kelompok": "K05",
  "topik_pilihan": 1,
  "nama_topik": "Convolutional Neural Network (CNN)",
  "judul_proyek": "Deep Learning-Based Plant Disease Identification Using Convolutional Neural Networks",
  "abstrak_singkat": "Proyek ini bertujuan untuk mengembangkan sistem identifikasi penyakit daun tanaman menggunakan pendekatan Deep Learning berbasis Convolutional Neural Network (CNN). Dataset yang digunakan berasal dari PlantVillage Dataset dengan fokus pada klasifikasi 5 jenis penyakit daun tomat. Proyek ini membandingkan performa baseline CNN dengan pendekatan transfer learning dan fine-tuning menggunakan MobileNetV2 untuk meningkatkan performa klasifikasi citra penyakit tanaman.",

  "metode_ai": [
    {
      "nama": "Custom CNN",
      "peran": "baseline",
      "varian": "CNN 3 blok konvolusi dengan filter 32, 64, dan 128, menggunakan Dropout 0.5 dan input 224x224",
      "catatan": "Digunakan sebagai baseline model awal yang dilatih selama 10 epoch menggunakan Adam Optimizer."
    },
    {
      "nama": "MobileNetV2",
      "peran": "utama",
      "varian": "Transfer Learning pretrained ImageNet dengan fine-tuning pada beberapa layer terakhir",
      "catatan": "Digunakan sebagai model utama untuk meningkatkan performa klasifikasi citra daun tomat melalui transfer learning dan fine-tuning."
    }
  ],

  "frameworks": [
    {
      "nama": "TensorFlow / Keras",
      "versi": "2.x",
      "kegunaan": "Framework utama untuk preprocessing data, arsitektur model, training, dan evaluasi model CNN serta MobileNetV2."
    },
    {
      "nama": "Google Colab",
      "versi": "Cloud Environment",
      "kegunaan": "Lingkungan eksperimen dan training model berbasis GPU cloud."
    },
    {
      "nama": "Matplotlib & Scikit-learn",
      "versi": "Terbaru",
      "kegunaan": "Digunakan untuk visualisasi accuracy/loss history, confusion matrix, classification report, dan evaluasi performa model."
    }
  ],

  "datasets": [
    {
      "nama": "PlantVillage Dataset (Tomato Disease)",
      "tipe": "publik",
      "sumber": "Kaggle",
      "url_sumber_publik": "https://www.kaggle.com/datasets/emmarex/plantdisease",
    }
  ]
}
```

```

    "jumlah_sampel": 7223,
    "jumlah_kelas": 5,
    "proses_akuisisi_mandiri": "",
    "peran_di_proyek": "Dataset utama yang digunakan untuk klasifikasi 5 kelas penyakit daun tomat, yaitu Healthy, Early Blight, Late Blight, Leaf Mold, dan Septoria Leaf Spot.",
    "spek_rl": null
  }
],

"metrik_utama": [
  "Accuracy",
  "Precision",
  "Recall",
  "F1-score",
  "Confusion Matrix",
  "Training/Validation Loss Curve"
],

"klaim_bonus": [
  "B1"
],

"anggota": [
  {
    "nama": "Nabiel Harits Utomo",
    "npm": "2306267044",
    "peran_utama": "Model Evaluation & Metadata Management",
    "focus_area": [
      "Preprocessing pipeline",
      "Model evaluation",
      "Confusion matrix analysis",
      "Metadata preparation"
    ],
    "konsep_dikuasai_implementasi": [
      "Image preprocessing",
      "Evaluation pipeline",
      "Accuracy/loss visualization",
      "Confusion matrix evaluation",
      "Classification report"
    ],
    "konsep_dikuasai_teoris": [
      "CNN architecture",
      "Performance metrics",
      "Model evaluation",
      "Deep Learning workflow"
    ],
    "bagian_laporan": [
      "BAB 2",
      "BAB 4",
      "Evaluasi",
      "Error Analysis"
    ],
    "bagian_kode": [
      "Preprocessing pipeline",
      "Evaluation pipeline",
      "Training notebook",
      "metadata.json"
    ]
  },
  {
    "nama": "Muhammad Pavel",

```

```

    "npm": "2306242363",
    "peran_utama": "Model Training & Transfer Learning",
    "focus_area": [
        "CNN training",
        "Transfer learning MobileNetV2",
        "Fine-tuning",
        "Training workflow"
    ],
    "konsep_dikuasai_implementasi": [
        "TensorFlow workflow",
        "Model training",
        "Transfer learning",
        "Fine-tuning MobileNetV2",
        "Training callbacks"
    ],
    "konsep_dikuasai_teorinya": [
        "CNN workflow",
        "Transfer learning",
        "Overfitting",
        "Deep Learning pipeline"
    ],
    "bagian_laporan": [
        "BAB 3",
        "Metodologi Implementasi"
    ],
    "bagian_kode": [
        "Training notebook",
        "Training configuration",
        "MobileNetV2 implementation",
        "Fine-tuning workflow"
    ]
},
{
    "nama": "R. Aisha Syauqi Ramadhani",
    "npm": "2306250554",
    "peran_utama": "Documentation & Preprocessing",
    "focus_area": [
        "Dataset visualization",
        "Data preprocessing",
        "Data augmentation",
        "README preparation"
    ],
    "konsep_dikuasai_implementasi": [
        "Dataset visualization",
        "Image preprocessing",
        "Data augmentation",
        "Markdown formatting"
    ],
    "konsep_dikuasai_teorinya": [
        "Data preprocessing",
        "Image augmentation",
        "CNN input preparation",
        "Documentation workflow"
    ],
    "bagian_laporan": [
        "BAB 1",
        "Dataset",
        "Preprocessing"
    ],
    "bagian_kode": [
        "Notebook preprocessing",

```

```

        "Dataset visualization",
        "README"
    ]
},
{
    "nama": "Zhafira Zahra Alfarisy",
    "npm": "2306250636",
    "peran_utama": "Dataset Management & Visualization",
    "focus_area": [
        "Dataset organization",
        "Dataset loading",
        "Training visualization",
        "Evaluation visualization"
    ],
    "konsep_dikuasai_implementasi": [
        "Dataset handling",
        "Dataset loading",
        "Loss visualization",
        "Training visualization"
    ],
    "konsep_dikuasai_teoris": [
        "Performance metrics",
        "Overfitting",
        "CNN evaluation",
        "Dataset management"
    ],
    "bagian_laporan": [
        "BAB 1",
        "BAB 3",
        "Hasil Sementara"
    ],
    "bagian_kode": [
        "Dataset loading",
        "Dataset organization",
        "Evaluation visualization",
        "Training notebook"
    ]
}
],

"tautan": {
    "github": "https://github.com/rdnaishaa/CNN-Rabu-5.git",
    "colab": "https://colab.research.google.com/drive/1arQUrIQ1QtqBqx5VVRc9prN0uAEUS9vx?usp=sharing",
    "dataset_mandiri": null,
    "video_demo": "https://youtu.be/iilsrdh167I"
},

"ai_assistant_usage": {
    "digunakan": true,
    "tools": [
        "ChatGPT",
        "Google Gemini",
        "Claude"
    ],
    "bagian": [
        "Diskusi evaluasi model CNN dan MobileNetV2",
        "Review dokumentasi proyek dan laporan",
        "Validasi workflow training dan preprocessing",
        "Analisis hasil eksperimen dan visualisasi",
        "Penyusunan metadata proyek"
    ]
},

```



```
    "estimasi_persentase": 10  
  }  
}
```

LAMPIRAN B

Tautan Repositori & Dataset

GitHub repo:

<https://github.com/rdnaishaa/CNN-Rabu-5.git>

Google Colab:

<https://colab.research.google.com/drive/1arQUrIQ1QtqBqx5VVRc9prN0uAEUS9vx?usp=sharing>

Dataset mandiri:

Video demo: <https://youtu.be/illsrdh167I>

APPENDIX C

Research Participation Consent Form (*Informed Consent*)

C.1 Brief Explanation. *Research:* Development & validation of an *agentic AI* framework for supporting academic oral examinations. *Principal investigator:* Muhammad Firdaus Syawaludin Lubis, PhD, Department of Computer Engineering, Universitas Indonesia. *Co-investigator:* a final-year undergraduate student supervised by the principal investigator. *Contact:* chemfirus@gmail.com. *Ethics review status:* **under review**. *Context:* data collection is conducted alongside the oral examination of the AI course's final assessment. The oral examination is held as part of the academic assessment regardless of the participant's research-participation choice.

C.2 Data Collected. Final report (PDF) and metadata.json file; audio and video recordings of the oral examination; automatic transcripts derived from those recordings; lecturer's *judgment* scores (*ground truth*) and AI system's *judgment* scores (test variable). **Not collected:** biometric data other than voice/face, or personal data beyond what is contained in the academic report.

C.3 Data Management. Participant names and student IDs (NPMs) will be stored anonymously — replaced with participant codes (P001, P002, ...) prior to analysis. The code-to-identity mapping table is stored separately, encrypted, and accessed only by the principal investigator. Publications (journal articles, conference papers, theses) will not contain individual identities. Data is stored with encryption on infrastructure managed by the research team; retention is 5 years after the research concludes, after which the data is permanently deleted. Access is limited to the principal and co-investigators; no third party may access without an amendment to this *consent*.

C.4 Participant Rights. (1) The right to decline participation without affecting the course grade. (2) The right to partial participation (e.g. report/metadata may be used, video recording may not). (3) The right to withdraw data at any time **until 30 June 2026** by emailing the principal investigator with the subject [Withdrawal] - [Name] - [NPM]; confirmation of deletion is provided within ≤ 7 working days. After 30 June 2026 the data will have entered the analysis phase and withdrawal becomes impractical. (4) The right to ask questions at any time to the principal investigator. (5) The right to receive a summary of the research findings once they are published (sent to the registered email).

C.5 Individual Consent. Each member completes their personal block on the following pages — one page per member. Tick **exactly one** of the three options (A / B / C), then sign with a wet signature or an *e-signature*.

Individual Consent — Member 1

Full name : Nabel Harits Utomo
Student ID (NPM) : 2306267044
Email : nabelutomo@gmail.com

I have read Sections C.1–C.4 and understood their contents. I voluntarily choose the following option:

- ☐ **Option A — Full Participation.** I consent to the use of my report, metadata, **and** the audio and video recordings of my oral examination for research purposes.
- ☒ **Option B — Limited Participation.** I consent to the use of my report, metadata, and audio recording, **but I do not consent to the video recording** of my oral examination being used for research. (The video recording will be deleted after the academic assessment is completed.)
- ☐ **Option C — Decline Participation.** I decline to participate in the research. (The academic oral examination proceeds as usual; there is no consequence to the grade.)

Participant's signature

Witness / researcher's signature



Nabel Harits Utomo

Date: 25 Mei 2026

()

Date:

Individual Consent — Member 2


Full name : Muhammad Pavel
Student ID (NPM) : 2306242363
Email : muhammadpavel4@gmail.com

I have read Sections C.1–C.4 and understood their contents. I voluntarily choose the following option:

- ☐ **Option A — Full Participation.** I consent to the use of my report, metadata, **and** the audio and video recordings of my oral examination for research purposes.
- ☒ **Option B — Limited Participation.** I consent to the use of my report, metadata, and audio recording, **but I do not consent to the video recording** of my oral examination being used for research. (The video recording will be deleted after the academic assessment is completed.)
- ☐ **Option C — Decline Participation.** I decline to participate in the research. (The academic oral examination proceeds as usual; there is no consequence to the grade.)

Participant's signature

Witness / researcher's signature



Muhammad Pavel

Date: 25 Mei 2026

()

Date:


Individual Consent — Member 3

Full name : R. Aisha Syauqi Ramadhani
Student ID (NPM) : 2306250554
Email : raishasyauqi7@gmail.com

I have read Sections C.1–C.4 and understood their contents. I voluntarily choose the following option:

- ☐ **Option A — Full Participation.** I consent to the use of my report, metadata, **and** the audio and video recordings of my oral examination for research purposes.
- ☒ **Option B — Limited Participation.** I consent to the use of my report, metadata, and audio recording, **but I do not consent to the video recording** of my oral examination being used for research. (The video recording will be deleted after the academic assessment is completed.)
- ☐ **Option C — Decline Participation.** I decline to participate in the research. (The academic oral examination proceeds as usual; there is no consequence to the grade.)

Participant's signature



R. Aisha Syauqi Ramadhani

Date: 25 Mei 2026

Witness / researcher's signature

()

Date:

Individual Consent — Member 4

Full name : Zhafira Zahra Alfarisy
Student ID (NPM) : 2306250636
Email : alfarisyzahra@gmail.com

I have read Sections C.1–C.4 and understood their contents. I voluntarily choose the following option:

- ☐ **Option A — Full Participation.** I consent to the use of my report, metadata, **and** the audio and video recordings of my oral examination for research purposes.
- ☒ **Option B — Limited Participation.** I consent to the use of my report, metadata, and audio recording, **but I do not consent to the video recording** of my oral examination being used for research. (The video recording will be deleted after the academic assessment is completed.)
- ☐ **Option C — Decline Participation.** I decline to participate in the research. (The academic oral examination proceeds as usual; there is no consequence to the grade.)

Participant's signature



Zhafira Zahra Alfarisy
Date: May 25th 2026

Witness / researcher's signature

()

Date: